

Predikce diabetu — Rozhodovací strom

PETR JEŽEK · 2026 · INTRO DO AI


01 Vliv parametrů na přesnost

Byly testovány různé kombinace hyperparametrů za účelem pochopení jejich vlivu na přesnost. Uvedená tabulka shrnuje zjištění od nejvíce ovlivňujících po nejméně ovlivňujících.


PARAMETR	POUŽITÁ HODNOTA	VLIV	POZOROVANÝ EFEKT
max_depth	5	VYSOKÝ	Nejvýznamnější parametr. Bez omezení dochází k přeučení (overfittingu) stromu — dosahuje ~100% přesnosti na trénovacích datech, ale pouze ~68 % na testovacích datech.
max_leaf_nodes	30	VYSOKÝ	Omezuje celkový počet listů, čímž strom prořezává (pruning) upřednostňováním nejčistších dělení. Společně s max_depth měly tyto dva parametry největší vliv na schopnost modelu generalizovat.
min_samples_split	7	VYSOKÝ	Požadavek na alespoň 7 vzorků před rozdělením uzlu zabránil stromu v "učení se" šumu. Hodnoty nad 10 způsobily nedoučení, takže rozmezí 5–10 přineslo nejlepší výsledky.
criterion	entropy	STŘEDNÍ	Přechod z výchozí hodnoty gini na entropii zlepšil přesnost zhruba o 0.5–1.0%.
min_samples_leaf	7	NÍZKÝ	Sám o sobě přesnost nijak znatelně nezměnil. Jeho hlavním efektem bylo vyhlazení grafu stromu, který se stal čitelnějším díky eliminaci nadbytečných listů.

02 Přesnost a preciznost vs. velikost trénovací sady

Model byl trénován na všech 15 poměrech rozdělení trénovacích a testovacích dat (1/16 až 15/16). Byly vytvořeny dvě varianty: bez fixního náhodného seedu a s `random_state=42`. Zlatý bod označuje nejlepší přesnost v daném běhu.



Bez fixního `random_state`



S `random_state=42`

POZOROVÁNÍ

Oba grafy vykazují podobný trend: přesnost vrcholí kolem velikosti trénovací sady $\approx 0,75-0,85$ a poté klesá, protože menší počet testovacích vzorků činí vyhodnocení méně spolehlivým. Preciznost vykazuje mnohem větší rozptyl u malých trénovacích sad, kde modelu chybí dostatek pozitivních příkladů k tomu, aby spolehlivě "porozuměl" datům.

03 Nejlepší konfigurace a výsledky

Bylo využito všech 8 příznaků. Napříč všemi natrénovanými stromy se **glukóza** pokaždé objevuje jako kořenový uzel. BMI a věk jsou také důležité a konzistentně se objevují ve druhé a třetí úrovni. Příznaky **pedigree** a **počet těhotenství** přispívají v hlubších větvích. Inzulin, tloušťka kůže a krevní tlak mají nejmenší vliv.

```
DecisionTreeClassifier(  
    criterion      = 'entropy',  
    max_depth     = 5,  
    max_leaf_nodes = 30,  
    min_samples_split = 7,  
    min_samples_leaf  = 7,  
)  
  
train_size ≈ 0.80 (nejvýkonnější oblast)
```

PŘESNOST

≈78 %

PRECIZNOST

≈73 %

SENZITIVITA


≈61 %

VELIKOST TRÉN. SADY


≈80%

Při výběru nejlepšího modelu nebyl použit žádný fixní `random_state`. Při ověření mnoha opakovanými běhy se přesnost konzistentně pohybuje v rozmezí 74–78 % — výsledky jsou statisticky signifikantní.

Oranžové uzly predikují *Bez diabetu*, modré uzly predikují *Diabetes*. Intenzita barvy odráží čistotu uzlu.



Obr. A – Nejlepší strom (bez fixního random_state) · Kořen: glucose ≤ 127,5 · hloubka 5 · 30 listů



Obr. B – Nejlepší strom (random_state=42) · Kořen: glucose ≤ 154,5 · hloubka 5 · 30 listů