

Sémantika

Sémantika přirozených jazyků

Sémantika: Vztah mezi **znaky** a **věcmi, které označují**.

V **lingvistice** je **sémantika** oborem, který se věnuje studiu významu na různých úrovních: slova, fráze, věty a větší jednotky **diskurzu** (rozsáhlejší texty). Tradiční sémantika zahrnuje studium **významu** a **referencí**, **pravdivostní podmínky**, **argumentovou strukturu**, **tématické role**, **analýzu diskurzu**, a vztah všech těchto oblastí k syntaxi.

Velmi populárním odvětvím sémantiky se v poslední době stala **postojová analýza (sentiment analysis)**. Studuje metody klasifikace vět podle jejich kladného nebo záporného významu.

Základní pojmy

Lexikální význam (Word sense) označuje jeden z (více) významů daného slova

Reference je relace mezi objekty, v níž je jeden objekt odkazuje na jiný objekt (např. zájmeno odkazuje na nějaké konkrétní podstatné jméno).

Tématické role vyjadřují význam, který nějaká jmenná skupina (noun phrase) zastává vzhledem k akci nebo stavu popsanému hlavním slovesem věty. Např. ve větě „Zuzana jedla jablko“ je Zuzana aktivním objektem, který provozuje konzumaci, je tedy agentem; jablko je naproti tomu objektem, který je konzumován, je to tedy paciens.

Analýza diskurzu (Discourse Analysis), je obecným termínem pro množinu přístupů k analýze psaného, mluveného nebo znakového jazyka používaného v textech většího rozsahu (než jedna věta).

Syntaxe a sémantika

Popis syntaxe umožňuje rozlišit gramaticky správně a nesprávně utvořené věty.

Gramatická správnost matematických výrazů:

$3+2$; $3*2=6$; $3/0$ správné

$3+*2$; $=7/2$ nesprávné

Správné (syntakticky) české věty:

Kulatý obdélník zeleně masíroval kouř vedle minuty.

Před čtvrtkem následuje pátek.

Pes Alík je veselý a smutný.

Premiér Klaus má dlouhé černé vlasy.

Jestli mi bude oběd chutnat, přidám si.

Význam a pravdivost

Význam a **pravdivost** sdělení v přirozeném jazyce jsou dvě naprosto odlišné záležitosti! I nepravdivá sdělení mají svůj význam, u jiných zase není možné ověřit pravdivost.

Jde o věty se stejným významem?

Hlavní budova FEL ČVUT je hned vedle Vítězného náměstí.
Hlavní budova FEL ČVUT je hned vedle Kulaťáku.

Studenti se stravují v menze.
Studenti se smějí stravovat v menze.
V menze se stravují studenti
V menze se smějí stravovat studenti.

Tuto knihu vydalo nakladatelství Paseka.
Tato kniha byla vydána nakladatelstvím Paseka.

Pozorovali ho dobrovolně.
Byl jimi pozorován dobrovolně.

Sémantika přirozeného jazyka

Vyplývání – to, že je věta pravdivá, mívá důsledky, věta nese víc informací:

Karel prodal auto sousedovi => Karel měl auto, už ho nemá, soused je od něj koupil a teď ho má

Pozor!

Tučňáci jsou ptáci ?=>? Tučňáci mají křídla a létají?

Sémantika formálních jazyků často spojuje pravdivost s významem, pro přirozené jazyky je nutné zvolit jiné teorie.

Fregeho princip kompozicionality

(Gottlob Frege, 1848-1925)

Význam složeného výrazu je jednoznačně určen významy jeho částí a způsobem jejich kombinace.

Lexikální sémantika

Význam slov můžeme popisovat zase pouze pomocí nějakého (meta)jazyka:

- formálního (vhodný matematický nebo logický kalkul či soustava sémantických rysů, sémů)
- přirozeného (téhož nebo jiného)

či v reálném světě kombinací jazyka a situace (předmětu):

Toto je křída.

Význam ale závisí i na kontextu:

Střílení poslanců ohrožuje naši křehkou demokracii.

(příklad převzat od prof. Paly z MUNI)

Lexikální sémantika

Význam slov můžeme nezávisle na kontextu popisovat pomocí významových (sémantických) tříd (rysů).

Ontologie = množina tříd objektů, která představuje strukturovanou klasifikaci objektů universa U , např.:

- fyzické objekty
- kvantity
- vztahy
- vlastnosti
- akce atd.

Tyto třídy lze dále zjemňovat: slovesa pohybu, péče o tělo, změny, komunikace apod.

Existují **doménové** (domain, zaměřené oborově) a **vrcholové** (upper, zaměřené všeobecně) ontologie.

Význam slov ale není jednoznačný: *kohoutek, štěně, hlava*
Pro jednotlivé dílčí významy používáme termín **Lexikální význam**

Popis významu slov

Ve slovnících

- pomocí synonym, např. OALD, SSJČ,
- pomocí definic,
- pomocí množiny vybraných primitivních výrazů daného přír. jazyka,
- pomocí speciálního metajazyka: sémantických rysů, např.

muž = HUM, MASK, ADU

dívka = HUM, FEM, -ADU

Pomocí sémantické sítě

- forma sémantické sítě lépe zachycuje víceznačnosti
- je možné pracovat s hierarchií pojmů
- výhodnější pro počítačové zpracování

Sémantická síť

WordNet

1993 George A. Miller z Princetonu:

<http://wordnet.princeton.edu>

- WordNet® je rozsáhlá lexikální databáze angličtiny obsahující podstatná a přídavná jména, slovesa a příslovce seskupená do množin synonym (synsetů). Každý synset vyjadřuje určitý koncept, jsou mezi sebou navzájem propojeny sémantickými a lexikálními relacemi.
- Celou síť je možno procházet pomocí prohlížeče.
- WordNet je veřejný, je možné si jej stáhnout.
- Ve verzi 3.0 obsahuje téměř 155 000 hesel a 117 000 synsetů.

Příklad z WordNetu

Chair

Noun

- S: (n) **chair** (a seat for one person, with a support for the back) *"he put his coat over the back of the chair and sat down"*
- S: (n) **professorship**, **chair** (the position of professor) *"he was awarded an endowed chair in economics"*
- S: (n) **president**, **chairman**, **chairwoman**, **chair**, **chairperson** (the officer who presides at the meetings of an organization) *"address your remarks to the chairperson"*
- S: (n) **electric chair**, **chair**, **death chair**, **hot seat** (an instrument of execution by electrocution; resembles an ordinary seat for one person) *"the murderer was sentenced to die in the chair"*

Verb

- S: (v) **chair**, **chairman** (act or preside as chair, as of an academic department in a university) *"She chaired the department for many years"*
- S: (v) **moderate**, **chair**, **lead** (preside over) *"John moderated the discussion"*

Sémantická síť

EuroWordNet

V roce 1997 prof. Vossen z Amsterdamu založil EuroWordnet 1 obsahující holandštinu, italštinu a španělštinu. K němu přibyl v roce 1998 EuroWordNet 2 s francouzštinou, němčinou, češtinou a estonštinou.

Proti původnímu WordNetu zavedeny změny:

- vrcholové ontologie (63 nejdůležitějších jazykově nezávislých konceptů)
- množiny základních konceptů (1000 základních konceptů tvořících jádra sítí slov, jazykově závislé)
- jazykově nezávislý soubor indexů (interlingual index - ILI) propojuje ekvivalentní výrazy napříč jazyky
- vztahy ekvivalence (EQ-relations)
- na rozdíl od anglického Wordnetu není k dispozici zdarma

Aplikace WordNetu

- Automatický překlad – může fungovat jako slovník
- IE – extrakce informací
jednak umožňuje pracovat se sémantickými vztahy (zejména synonymie), jednak může sloužit při vícejazyčném vyhledávání
- Určování jednotlivých významů slov (Word Sense Disambiguation) – zdroj dat pro rozpoznávání jednotlivých významů
- Reprezentace znalostí, odvozování využívající významů slov, vztah k sémantickému Webu
- Vyhodnocování kvality překladu (zlepšení automatických metrik typu BLEU)

WordNety pro jiné jazyky než angličtinu byly často vytvářeny překladem anglického originálu, což rozhodně negativně ovlivnilo jejich kvalitu.

Reprezentace významu věty

Predikátová logika 1.řádu

Konstruuje logické formule z jednotlivých výrazů věty na základě principu kompozicionality – jednotlivým složkám věty náleží odpovídající části sémantického zápisu

Alík skáče $\text{jump}(\text{Alík}), \exists x x=\text{Alík} \ \& \ \text{jump}(\text{Alík})$

Všichni psi skáčou $\forall x \text{dog}(x) \rightarrow \text{jump}(x)$

Každý student podepsal petici $\forall x \text{student}(x) \rightarrow \exists y \text{petition}(y) \ \& \ \text{sign}(x,y)$

Petici podepsal každý student $\exists y \text{petition}(y) \ \& \ \forall x \text{student}(x) \rightarrow \text{sign}(x,y)$

Reprezentace významu věty

Hranice predikátové logiky 1.řádu

Modalita, čas a postoj – nové operátory, které mají jako argumenty formule

possible(F), necessary(F)

believe(x,F)

true_at_some_time_in_the_future(F)

Presupozice

Předpoklad, který musí být pravdivý, aby celá věta vůbec měla pravdivostní hodnotu

Jupiterův měsíc má oranžové pruhy. – Jupiter musí mít právě jeden měsíc.

Neurčitost (Fuzziness)

Nevystačíme s T/F hodnotami, potřebujeme jemnější dělení:

Pavel je mladý. Většina špičkových sportovců dopuje.

Rozpoznávání vztahů v textu

Anafora

Výraz, jehož interpretace závisí na kontextu. Obecně rozlišujeme:

- Exoforma (odkazování mimo text)

Vidíš ho? Dejte mi, prosím, tyhle tři.

- Endoforma (odkazování v rámci textu)

- Anafora (zpětně)

*Petr se seznámil se sympatickou dívkou. Pozval ji do kina.
Petr vyzradil tajemství. To neměl dělat.*

- Katafora (dopředu)

*Když se zlobí, není s Petrem žádná řeč.
Věřte tomu nebo ne, máme schodkový rozpočet.*

Vyšel jsem z domu. Věděl jsem, že jsem sledován. Když jsem se zastavil, zastavil se i on. Když jsem se ohlédl, dělal, že lelkuje. Měl na sobě stejný šedý kabát jako vždycky. Už ho důvěrně znám, estébáka Jiřího.

Anafora

Anaforický vztah **předchůdce – následník**

Typy anaforických vztahů:

Zájmena a „nulové výrazy“ (nevyjádřený podmět nebo jiný větný člen)
Petr si koupil vstupenku. Vsunul ji do kapsy. Byla děravá.

Určité jmenné skupiny (*Elektronický zesilovač Tesla vs. Toto zařízení...*)

Elipsa (vypuštěné části výrazů na základě paralelismu s předchůdcem)
jmenná vs. slovesná

Včera jsem šel pěšky. Kam? Domů.

Petr přinesl dva stoly. Dřevěný a kovový.

Petra půjde do kina. Jirka taky.

Textové spojovací výrazy (výrazy vyjadřující mezivětné souvislosti v textu) – např. souřadicí a podřadicí spojky a výrazy jako *například, na jedné straně – na druhé straně, jednak –jednak, nejdříve – potom* apod.

Anafora

Důležitost pro aplikace

Získávání informací z textu

Škoda představila nový model Octavie. Jde o pětidveřové kombi, které má

Automatický překlad

*Otevřenou tabulku upravte podle potřeby. Uložte **ji** pomocí ikony v panelu nástrojů.*

Dialogové systémy

Kdy jede nejbližší vlak do Ostravy? Má jídelní vůz?

Uživatel: *Které vzorky obsahují magnézium?*

Systém: *ID123, ID147, ID159, ID369*

Uživatel: *Které obsahují (také) křemík?*

Řešení anafory

Je nutné využít celou řadu informací:

- morfologické značky
 - např. u zájmen musí být shoda v rodě
- syntaktická struktura věty
 - pomůže určit vhodné kandidáty na předchůdce
 - valenční informace umožní doplnit elipsu
- statistické přístupy
 - pravděpodobnost výběru některého z určených kandidátů
- aktuální členění
 - témata zmíněná v základu a v ohnisku věty jsou odkazována různými způsoby – využito v algoritmu Zásoby sdílených znalostí
- rozsáhlé pomocné znalosti
 - ontologie, sémantické sítě, tezaury apod.

Zásoba sdílených znalostí

Modeluje zásobu znalostí, o které mluvčí předpokládá, že ji sdílí s posluchačem. Tato zásoba se mění v souladu s tím, co je „v centru pozornosti“ v daném časovém okamžiku.

Každá věta má vliv na tuto „hierarchii sdílení,“ avšak ne každý zmíněný objekt má stejný účinek.

Jednoduchá pravidla:

Objekt **a**, jenž má stupeň sdílení **n**, je označen jako **aⁿ**

Pokud k **a** referujeme slabou formou zájmeny nebo pokud je vynecháno, zůstává **n** stejné

Pokud je jmenná skupina **a** zmíněna v **ohnisku**, potom $a^n \rightarrow a^0$

Pokud je jmenná skupina **a** zmíněna v **jádru**, $a^n \rightarrow a^1$

Pokud $a^n \rightarrow a^m$ potom všechny objekty asociované s **a** obdrží hodnotu a^{m+2}

Výrazy „As for a“, „Concerning a“ atd. zvýší aktivaci na a^1

Pokud není **a** ani zmíněno, ani asociováno, potom se jeho stupeň aktivace zvýší o 2

Zásoba sdílených znalostí

Příklad

[1] The school garden was full of children.

[2a] They talked noisily,

[2b] but the teachers did not reprove them,

[2c] because they were so excited.

[3] Outside parents were waiting.

[4] A group of about five parents grouped around a microphone.

[5] One of them should probably speak.

[6] The teachers were very serious.

[1] children⁰ school garden¹ parents² school³ pupils³

[2a] children⁰ parents² school garden³ school⁵

[2b]

[2c]

[3]

[4]

[5]

[6]