

Strojový překlad

Kageru-to mugade hala jo deka medsene seno gejay!

kageru = sejít se, shromáždit se, oženit se

mugade = hlava

hala = skupina

jo = jeden, jedna

deka = pět

medse = hodina

seno = velký

jay = muž, vládce

Překlad:

*Sejít se hlava skupina jeden pět ?hodina?
velký (?muž, vládce?).*

Co nám chybí?

Tvarosloví (morfologie)

<Sloveso> + to = Budoucí čas

Přípona -ne = 6.pád (časová předl. v)

Předpona ge- = 9.pád (místní určení)

*Sejde se hlava skupina jeden pět v
hodině velký u muže.*

"Pravidla domorodého pravopisu"

- v oznamovacích větách domorodci používají pevný pořádek slov, kde se za slovesem ostatní větné členy seřadí podle své důležitosti, počínaje podmětem.
- systém číslovek se podobá římským číslům - *jeden pět* znamená *čtyři*.
- přídavná jména, zájmena a číslovky vždy rozvíjejí bezprostředně následující jména podstatná

Sejde se hlava skupina ve čtyři hodiny u velkého muže

Ustálená spojení

mugade hala se má překládat buď jako *skupina moudrých* nebo ještě lépe jako *rada starších*

seno jay není *velký muž*, ale *náčelník*

Rada starších se sejde ve čtyři hodiny u náčelníka

Problémy překladu – rozdíly ve významu

anglicky				japonsky		
cook	bake			YAKU		↑ Pouze žár
	toast					
	roast					
	broil					
		barbecue	ITAMERU		↓	
		grill				
	fry	stir-fry sauté		AGERU FRY NI SURU TEMPURA NI SURU ITAMENI NI SURU		↑ Váření na oleji
		deep-fry French-fry				
		braise				
boil	simmer	stew	NIRU TAKU		↑ Váření	
	boil	poach				
			YUDERU		↓ ve vodě	
	steam		MUSU, FU			

Víceznačnost slov

Remove the spark plugs	Zündkerzen herausdrehen
Remove the plug leads	Zündkabel abziehen
Remove the dipstick	Öhlmeßstab herausziehen
Remove the filter cap	Verschlußkappe aufdrehen
Remove the distributor cap	Verteildeckel abnehmen
Remove the rotor arm	Verteilerläufer abziehen
Remove nipple	Schmiernippel herausdrehen
Remove the two bolts	Beide Schrauben lösen

Složené výrazy

... remove defective *left wing tip tank filler gap gasket*...

těsnění plnicího otvoru nádrže konce levého křídla

... airport long term car park courtesy vehicle pickup point ...

Mädchenhandelsschule

Donaudampfschiffahrtsgesellschaftskapitänwitwe

Nonstop x Durchgehend




Prehistorie

1933 patenty pro překladové stroje:

George Artsruni

P.P Smirnov-Trojanskij



Trojúhelník strojového překladu

Analýza

V této fázi probíhá typicky morfologická a syntaktická analýza, někdy dokonce doplněná (částečnou) sémantickou analýzou.

Transfer

Tato fáze má za úkol převést do cílového jazyka nejen lexikální jednotky, ale také transformovat syntaktický strom zdrojového jazyka do stromu jazyka cílového (např. změnit pořádek slov podle pravidel cílového jazyka apod.) či provést jiné transformace.

Generování

Bere (syntaktický) strom věty cílového jazyka a jeho postupným rozpouštěním generuje jeho syntakticky a morfologicky správnou povrchovou formu.

Interlingua

Logická (formální) reprezentace významu věty společná pro oba jazyky. Jedná se více či méně o teoretický koncept, protože žádná taková obecně akceptovaná formální reprezentace významu (zatím) neexistuje.

Metody první generace

- Automatický dvojjazyčný slovník, text zpracováván slovo od slova
- Ve slovníku nejsou zachycena celá slova, ale předpony, kmeny a přípony zvlášť
- Zjednodušení vstupního textu prostřednictvím preeditingu
- Úprava výstupního textu pomocí posteditingu
- Použití jednoho přirozeného jazyka jako tzv. pivotního pro překlad do více jazyků

První úspěch

Georgetownský experiment (1954 - 1956)

Úspěšný experiment založený na striktním omezení domény a používaných jazykových prostředků:

45 vět s 250 slovy, 6 syntaktických „zákonů“, jednoduché oznamovací věty, bez negací, slovesa ve 3. osobě, málo předložek

Bouřlivý rozvoj

1955 Anglo-ruský překlad v Moskvě

1956 První mezinárodní konference
12 vědeckých skupin na amerických univerzitách

1957 NoamChomsky - Standard theory

1960 Yehuda Bar Hillel: „Vysoce kvalitní plně automatický
překlad nemůže být nikdy dosažen.“
„The box was in the pen.“

Příklon k teorii, práce se syntaxí jazyka, druhá generace
systémů


Vystřízlivění

1966 Zpráva **ALPAC** (American Language Processing Advisory Committee)

- Konstatuje nutnost investic do dlouhodobého teoretického lingvistického výzkumu.
- Faktický důsledek: konec podpory

Zpráva nebyla negativní,
negativní byly její důsledky

Práce mimo USA pokračovaly (Francie, SSSR, Kanada)



Období po ALPACu

„Doba temna“

Existují výjimky:

- SYSTRAN (konec 60.let)
- skupina GETA v Grenoblu (vznikla 1961)
- SUSY (Saarbruecken)
- LOGOS (Texas)
- TAUM (Montreal)
- ETAP (Moskva)

První úspěšný komerční systém:

TAUM - METEO (1976)

- překlad meteorologických zpráv A->F
- dobře definovaná a výrazně syntakticky i sémanticky omezená podmnožina jazyka
- vhodné implementační prostředky (Q – systémy)
- systém sám rozezná text, který mu dělá potíže, a předá jej lidskému překladateli
- v 90.letech překládali 45 000 slov denně

Další významné systémy I.

SYSTRAN

- Překlad dokumentů EU
- Přímý překlad (každý pár řešen zvlášť) mezi cca 20 páry, ovšem uspokojivá kvalita pouze u nejstarších párů (A-F-N)
- Data oddělena od programu
- Problémy řešeny ad hoc

EUROTRA

- Oficiální projekt EU v 80.letech
- Megalomanie: 72 jazykových párů
- Nezvládnutá modularita
- Do jisté míry podobný negativní efekt jako zpráva ALPAC

Strojem podporovaný překlad (Computer Assisted Translation)

Komerčně původně (před érou Google Translate) mnohem úspěšnější než plně automatické systémy strojového překladu. Systémy CAT se objevily na trhu v polovině 80. let.

Jsou založeny na využití paralelních textů v tzv. **překladové paměti**. Jsou vhodné zejména pro opakované překlady mírně aktualizovaných textů (např. nových verzí technických manuálů).

Překladová paměť (Translation Memory - TM) obsahuje páry přeložených **segmentů** (typicky vět nebo klauzí), obohacené o sadu metadat, umožňujících efektivní spravování pamětí.

Věty ze vstupního textu se vyhledávají v paměti, a pokud jsou nalezeny, překladatel obdrží **návrh překladu** (odpovídající větu cílového jazyka získanou z paměti) s barevně **zvýrazněnými odlišnostmi** a informace o **procentech podobnosti**. Překladatel se pak rozhodne, zda bude návrh upravovat, nebo zda přeloží celou větu znovu. Praxe ukazuje, že při shodě <70% je lepší větu přeložit celou znovu.

Strojem podporovaný překlad

2 základní přístupy:

- Překlad **věta po větě**, každá z nich je postupně vyhledávána v překladové paměti. Překladač vidí kontext zdrojového textu, každý výskyt věty je nutné přeložit znovu (dokonce i když se věta v textu opakuje)

Původní myšlenka byla implementována v programu **IBM Translation Manager**, komerční standard byl nastaven firmou **TRADOS** (produktu se nyní jmenuje **TRADOS Studio**)




- Překlad prostřednictvím vyplňování **překladové tabulky**
Překladač nevidí kompletní kontext, ale překládá každou větu pouze jednou (i ty opakované)

Reprezentant: **Déjà Vu**



Trados Studio



Déjà Vu

All Except Locked Segments		Norwegian (Bokmål)	
English (Canada)		Norwegian (Bokmål)	
{701}Push{702} and turn the key 1/4{703} turn counterclockwise to the front storage compartment position and hold while lifting cover.	✓ !	{701}Trykk inn{702} og vri nøkkelen en kvart{703}omdreining mot klokka for å åpne frontbagasjerommet, og hold mens du løfter dekslet.	
The tool kit is located inside the front storage compartment.	✓ !	Verktøysettet er plassert inne i frontbagasjerommet.	
The operator's guide is located with the {704}safety DVD{705} video inside the front storage compartment.	✓ !	Brukerhåndboken og en {704} sikkerhetsvideo på DVD{705} ligger i frontbagasjerommet.	
typical - Left Hand Side Panels	✓ !	typebilde – Venstre sidepaneler	
typical - INNER SIDE OF PANEL	✓ !	typebilde – INNSIDEN AV PANELET	
Make sure the clip is properly inserted in the footrest support.	✓ !	Pass på at klipsen er satt ordentlig inn i <u>fotstøtten</u> .	
Use {720}Cable lubricant{721} or the equivalent	✓ !	Bruk {720} <u>kabelsmøremiddel</u> {721} eller tilsvarende	
You do not need to use the reverse button	✓ !	Du trenger ikke å bruke reversknappen –	✓

Exportovaná překladová paměť

<RTF Preamble>

<FontTable>

{\fonttbl

{\f1 \fmodern\fprq1 \fcharset0 Courier New;}

{\f2 \fswiss\fprq2 \fcharset0 Arial;}

{\f3 \froman\fprq2 \fcharset2 Symbol;}

{\f4 \froman\fprq2 {*\falt Times}\fcharset0 Times New Roman;}

{\f5 \froman\fprq2 {*\falt Times}\fcharset0 Times New Roman CE;}

...

<TrU>

<CrD>04021999

<CrU>SAP1

<Att L=Subunit>DOC

<Txt L=Text Field>ASAP_2/99

<Seg L=CS_01>Zahrňte informace o tom, jaká bude spolupráce technického a aplikačních týmů).

<Seg L=PL_01>Włączcie informacje o tym, jaka będzie współpraca technicznego a aplikacyjnych teamów).

</TrU>

← Hlavička souboru

Přidaná metadata

Segment zdrojového jazyka

Segment cílového jazyka

Naše experimenty - RUSLAN

- Překlad manuálů k operačním systémům sálových počítačů v letech 1985-90
- Implementace v roce 1989 na PC AT 286
- Překlad 1 věty cca 4 minuty
- Dvojjazyčný slovník o velikosti cca 8500 slov
- Transdukční slovník
- Klasická architektura: Analýza, transfer, syntéza
- Gramatika zapsána pomocí Q-systémů (TAUM)
- Záchranná pravidla pro případ problémů při syntaktické analýze
- Výzkum zastaven v roce 1990 těsně před provozními zkouškami

Systém RUSLAN

Transdukční slovník

Jedná se o **algorithmus**, který využívá faktu, že některá slova založená na řeckém nebo latinském základu se dají přímo převést do cílového jazyka pouhým přepsáním koncového úseku:

-ation => **-ace** => **-acija**

industrialization => industrializ**ace** => industrializ**acija**

-ical => **-ický** => **-ičeskij**

statistical => statist**ický** => statist**ičeskij**

Ukázalo se, že TS pro překlad **A** -> **Č** i **Č** -> **R** se téměř neliší.

Fáze překladu I.

Vstupní věta

Určitý investiční prostředek je vždy přiřazen těmto organizačním jednotkám.

Technická transformace věty

-1- \$sn(5) + \$gs(l) + <zac + urc3ity2 + investic3ni2 +
prostředek + je + vz3dy + jednoznac3ne3 + pr3ir3azen + te3mto
+ organizac3ni2m + jednotka2m + iz(.) + >end + >-2-

Překlad „konstant“

-001- \$sn(5) + \$gs(l) + <zac + urc3ity2 + investic3ni2 + prostr3edek
+ je + 6(\$vsegda) + 6\$(odnoznac2no) + pr3ir3azen +
2(mefw(d(p)),pos,@(*),#(\$),%(mi48),\$(tot,\$za2(z2e,samyj))) +
organizac3ni2m + jednotka2m + iz(.) + >end + > + > -002-

Fáze překladu II.

Příprava na morfologickou analýzu

-001- \$sn(1) + \$gs(l) + *(<zac) + < -002-
-002- *(urc3ity2) -003-
-002- \$(u,r,c,3,i,t,y,2) -003-
-003- < -004-
-004- *(investic3ni2) -005-
-004- \$(i,n,v,e,s,t,i,c,3,n,i,2) -005-
-005- < -006-
-006- *(prostr3edek) -007-
-006- \$(p,r,o,s,t,r,3,e,d,e,k) -007-
-007- aux(h(m(s,3),e(s,3),f(s,3),w(s,3)),praes,#,\$(byt6)) + 6(\$ (vsegda)) +
6(\$ (odnoznac2no)) + < -008-
-008- *(pr3ir3azen) -009-
-008- \$(p,r,3,i,r,3,a,z,e,n) -009-
-009- 2(mefw(d(p)),pos,@(*),#(\$),%(mi48),\$(tot,\$za2(z2e,samyj))) + < -010-
-010- *(organizac3ni2m) -011-
-010- \$(o,r,g,a,n,i,z,a,c,3,n,i,2,m) -011-
-011- < -012-
-012- *(jednotka2m) -013-
-012- \$(j,e,d,n,o,t,k,a,2,m) -013-
-013- iz(.) + >end + *(>) + *(>) -014-

Slovník

URC3IT==M(MI2289,OPREDELENNYJ).

INVESTIC3N==J(MI2289,INVESTICIONNYJ).

PROSTR3EDK==H(@(*K),?(G(+(*C,*Z,OS,*R,*A),G),
PRO(A,+(*C,*R,*A),DLJA(G))),NI15,SREDSTVO).

PR3IR3AD==R(5,PRP,?(N(N),A(A),/,N(N),I(I),/,>,<,/,D(D)),15,PRISVOJIT6).

ORGANIZAC3N==J(MI2289,ORGANIZACIONNYJ).

JEDNOTK==Z(@(*A,*K),FI08,\$(EDINICA,\$ZA2(!SEGMENT,!MORF,MI01))).

Fáze překladu III.

Po průchodu slovníkem

-001- \$sn(1) + \$gs(l) + *(<zac) +
2(m(n(s)),e(n(s),a(s)),pos,@(*),#(\$),&,%(mi2289),\$ (opredelennyj),1(=,@(\$),#(\$),\$(\$))) +
2(m(n(s),n(p),a(p)),e(n(s),a(s),n(p),a(p)),f(n(s),g(s),d(s),a(s),
l(s),i(s),n(p),a(p)),w(n(s),a(s),n(p),a(p)),pos,@(*),#(\$),&,%(mi2289),\$
(investicionnyj),1(=,@(\$),#(\$),\$(\$))) +
1(e,/,n(s),a(s),/,@(*k,*a),#(<,/,g(g),pro(a,dlja(g)),na(a,dlja(a)),/,>,x(\$)),&,%(n
i15),\$ (sredstvo),1(=,@(\$),#(\$),\$(\$))) +
aux(h(m(s,3),e(s,3),f(s,3),w(s,3)),praes,#,\$ (byt6)),1(mefw,/,a(p),/,@(*,o
sob),#(\$),%(ma42),\$ (on),1(=,@(\$),#(\$),\$(\$))) + 6(#(\$),&,\$ (vsegda)) +
6(#(\$),&,\$ (odnoznac2no)) +
5(1(=,@(\$),#(\$),\$(\$)),h(m(s,1,2,3),e(s,1,2,3)),pas,ind,#(<,/,n(n),/,>,<,/,i(i),/,
>,<,/,d(d),/,k(d,k(d)),/,>,a,x(\$)),&,%(15),\$ (prisvojit6)) +
2(mefw(d(p)),pos,@(*),#(\$),&,%(mi48),\$ (tot,\$za2(z2e,samyj)),
1(=,@(\$),#(\$),\$(\$))) +
2(m(l(s),i(s),d(p)),e(l(s),i(s),d(p)),f(d(p)),w(l(s),i(s),d(p)),pos,
@(*),#(\$),&,%(mi2289),\$ (organizacionnyj),1(=,@(\$),#(\$),\$(\$))) +
z(@(*a,*k,*m),fi08,\$ (edinica,\$za2(!segment,!morf,mi01)))) +
iz(.) + >end + *(>) + *(>) -002-

Příklad gramatického pravidla

** JOINING ADJECTIVES AND NOUNS .

** AN ADJECTIVE FROM THE LEFT.

$2(U^*1, B^*(Y^*1), U^*2, A^*, @(W^*), #(\$), U^*3, 1(X^*1, \$(\$)))$
+ $1(B^*, Z^*1, /, Y^*2, /, Z^*2, @(V^*), Z^*3, \$(Z^*4), Z^*5)$
== $1(B^*, /, Y^*2, /, @(V^*), Z^*3, \$(Z^*4),$
 $2(A^*, U^*3, 1(X^*1, \$(\$))), Z^*5)$
/ (. Y*2 -DANS- Y*1
-OU- 4(\$2P) -DANS- Z*5 -ET- G(P) -DANS- Y*1 .)
-ET- Z*4 " C1
-ET- RS(+ (SP(V*)), -(V*)) -HORS- U*3
-ET- AD(+ (SP(W*)), -(W*)) -HORS- Z*3
-ET- -NON- (. RS(+) -DANS- U*3 -ET- RS(+ (V*)) -HORS- U*3
-OU- AD(+) -DANS- Z*3 -ET- AD(+ (W*)) -HORS- Z*3 .).

Fáze překladu IV.

Český syntaktický (pod)strom

-001- \$sn(1) + \$gs(l) +

v(h(e(s,3)),praes,pas,ind,#(<,,/,,>,<,,/,,i(i),/,,>,<,,/,,d(d),/,,k(d,k(d)),/,,>,a,x(n,x2(*),\$),&,%(15),\$(prisvojit6),1(n,e(s),j(/,a(s),/),@(*k,*a),#,t(n),&,%(ni15),\$(sredstvo),2(pos,&,%(mi2289),\$(opredelennyj),1(=,@(\$),#(\$),\$((\$))),2(pos,&,%(mi2289),\$(investicionnyj),1(=,@(\$),#(\$),\$((\$))),1(=,@(\$),#(\$),\$((\$))),1(laux,@(\$),#(\$),\$((\$)),aux(h(e(s,3)),praes,#,&,\$(byt6)),1(ladv,@(\$),#(\$),\$((\$)),6(#(\$),&,\$(vsegda)),1(ladv,@(\$),#(\$),\$((\$)),6(#(\$),&,\$(odnoznac2no)),1(=,@(\$),#(\$),\$((\$))) +

2(mefw(d(p)),pos,@(*),#(\$),&,%(mi48),\$(tot,\$za2(z2e,samyj)),1(=,@(\$),#(\$),\$((\$))) +

1(f,,/,,d(p),/,,@(*a,*k,*m),#(<,,/,,g(g),/,,>,x(\$)),&,%(fi08),\$(edinica,\$za2(!segment,!morf,mi01)),2(pos,#(\$),&,%(mi2289),\$(organizacionnyj),1(=,@(\$),#(\$),\$((\$))),1(=,@(\$),#(\$),\$((\$))) +

iz(.) + >end + *(>) + *(>) -002-

Fáze překladu V.

Po syntaktickém generování ruštiny

-001- \$sn(1) + \$gs(l) +
opredelennyj(\$(2,mi2289,sg,1,n,i)) +
investicionnyj(\$(2,mi2289,sg,1,n,i)) +
sredstvo(\$(1,ni15,sg,1)) +
vsegda +
odnoznac2no +
prisvojit6(\$(5,15,3,n,u,j,k,x)) +
tot(\$(2,mi48)) +
z2e +
organizacionnyj(\$(2,mi2289,pl,3,f,i)) +
edinica(\$(1,fi08,pl,3)) +
!segment(\$(1,mi01,pl,3)) + . -002-


Po morfologické synéze ruštiny

OPREDELENNOE INVESTICIONNOE SREDSTVO VSEGDA ODNOZNAC"NO
PRISVOJENO TOT Z"E ORGANIZACIONNYM EDINICAM !SEGMENTAM .

System Česílko

- Lokalizace velkých softwarových systémů
- Snaha minimalizovat lidský podíl na překladu
- Náhrada lokalizace z jazyka typově odlišného překladem z jazyka blízkého
- Typ překladu:
 - FAHQ (Plně automatický, vysoce kvalitní)
 - Velmi blízké jazyky
 - Statistické značkování češtiny
 - Dvojjazyčný slovník – slova nelze přímo přepisovat
 - Překládá se po jednotlivých slovech, značkování pomáhá určit správný překlad
- Ověření možnosti použití shodné technologie pro jiné páry (skupiny) jazyků

Využití příbuznosti



Příklad překladu / Rozdíly

- Z češtiny do slovenštiny:
 - Při zakládání třídy výkazů se *třídě* nejprve přidělí označení a *přiřadí* se skupině uživatelů.
=====>
 - Pri zakladaní triedy výkazov sa *triede* najprv prideli označenie a *priradí* sa skupine užívateľov.
- Shodná syntaxe
- Většinou shodné pořadí slov ve větě
- Odlišné slovníky (jistá pravidelnost)
- Odlišné tvarosloví
- Překlad slovo od slova
- Morfologická analýza je doplněna značkováním, aby bylo možné rozlišit např. překlady *jarní* => *jarný*, *jarná*, *jarné*

Výsledky překladu CZ-SK

Originál:

Výklad metodou postupných kroků o stávající situaci podnikového procesu, která existuje ve vašem *podnikání*.

Představuje popis formou scénáře, v němž normálně popíšete skutečnou situaci, ve které se nachází vaše podnikání. Nemusíte se zabývat podrobnými vstupními nebo výstupními požadavky, různými podmínkami nebo *očekávanými* hodnotami, neboť to je provedeno v kapitolách o konfiguraci a *testování*. Popis případu by měl být konzistentní s tokem podnikového procesu a měl by plně podporovat tok podnikového procesu, který je pro tento případ v *Základním seznamu podnikových procesů*. Jak se použijí tyto informace: jsou extrapolovány do specifikací konfigurace, které se použijí při konfiguraci vašeho systému R/3.

Překlad:

Výklad metódou postupných krokov o súčasnej situácii podnikového procesu, ktorá existuje vo vašom *podnikaníe*.

Predstavuje popis formou scenára, v ktorom normálne popíšete skutočnú situáciu, vo ktorej sa nachádza vaše podnikanie. Nemusíte sa zaoberať podrobnými vstupnými alebo výstupnými požiadavkami, rôznymi podmienkami alebo *očakávať* hodnotami, pretože to je vykonané v kapitolách o konfigurácii a *testovanie*. Popis prípadu by mal byť konzistentný s tokom podnikového procesu a mal by plne podporovať tok podnikového procesu, ktorý je pre tento prípad v *Business Process Master listov*. Ako sa použijú tieto informácie: sú extrapolované do špecifikácií konfigurácie, ktoré sa použijú pri konfigurácii vášho systému R/3.

Výsledky překladu CZ-PL

Originál:

Výklad metodou postupných kroků o stávající situaci podnikového procesu, která existuje ve vašem *podnikání*.

Představuje popis formou scénáře, v němž normálně popíšete skutečnou situaci, ve které se nachází vaše podnikání. Nemusíte se zabývat podrobnými vstupními nebo výstupními požadavky, různými podmínkami nebo *očekávanými* hodnotami, neboť to je provedeno v kapitolách o konfiguraci a *testování*. Popis případu by měl být konzistentní s tokem podnikového procesu a měl by plně podporovat tok podnikového procesu, který je pro *tento* případ v *Základním seznamu podnikových procesů*. Jak se použijí tyto informace: jsou extrapolovány do specifikací konfigurace, které se použijí při konfiguraci vašeho systému R/3.

Překlad:

Wystawa metodą postępowanych kroków o obecnej sytuacji zakładowego procesu, która istnieje w waszym *przedsiębiorstwo*.

Przedstawia opis formą scenariusza, w którym normalnie opiszeć rzeczywistą sytuację, w której się znajduje wasze przedsiębiorstwo. Nie Musicie się zajmować szczegółowymi wejściowymi czy zadanymi wyjściowymi, różnymi warunkami czy wartościami *oczekiwaniemi*, albowiem to jest wykonano w kapitułach o konfiguracji a *testowanie*. Opis wypadku miałyby być niespójny z płynięcie zakładowego procesu a miałyby do pełna wspierać płynięcie zakładowego procesu, który jest dla *ten* wypadek w *Liście głównym procesów biznesowych*. Jak się użyją te informacje: są ekstrapolacja do wyszczególnień konfiguracji, które się użyją przy konfiguracji waszego systemu R/3.

Asi nejlepší český komerční systém

Marsh & McLennan Cos. said it agreed to acquire the rest of Gradmann & Holler, a leading West German insurance brokerage firm in which it has held a 15% stake for 15 years. The transaction, for cash and stock, would represent the biggest European takeover since 1980 for New York-based Marsh & McLennan, the world's largest insurance broker. It's also the first major sign of the long-awaited consolidation in the European insurance industry as the European Community Commission moves toward a single market by 1992

PC Translator 2003 – tradiční přísup používající pravidla

Mokřina & McLennan kosinusy. řekly, že to souhlasilo se získat zbývající část Gradmann & křičí, vůdčí západní německý pojišťovací makléřská firma v kterém to držela 15% sázka pro 15 let. Transakce, za hotové a akcie, reprezentovala největší evropské převzetí od roku 1980 pro New York-založená mokřina & McLennan, světově největší pojišťovací agent. To je také první významnější znamení dlouho očekávaného upevnění v evropském pojišťovníctví jak Evropské společenství pověřovací pohyby směrem k jednotnému trhu do 1992.

Google Translate 2010 - statistika

Marsh & McLennan Cos. said it agreed to acquire the rest of Gradmann & Holler, a leading West German insurance brokerage firm in which it has held a 15% stake for 15 years. The transaction, for cash and stock, would represent the biggest European takeover since 1980 for New York-based Marsh & McLennan, the world's largest insurance broker. It's also the first major sign of the long-awaited consolidation in the European insurance industry as the European Community Commission moves toward a single market by 1992

Marsh & McLennan dohodnuta Cos. jí řekl, že k získání zbytku Gradmann & křičet, přední pojišťovací makléřství západoněmecké firmy, v nichž má v držení 15% akcií za 15 let. Tato transakce, za výběr hotovosti a akciích, by představovalo největší evropský převzetí od roku 1980 v New Yorku založena-Marsh & McLennan, který je největším na světě pojišťovací makléř. Je také prvním hlavním znakem je dlouho očekávaná-konsolidace v evropském pojišťovníctví, jako je Evropská společenství Komise podniká kroky směrem k vytvoření jednotného trhu do roku 1992

Data převzata z PennTreebanku

Google Translate 2018 – neuronové sítě

Marsh & McLennan Cos. said it agreed to acquire the rest of Gradmann & Holler, a leading West German insurance brokerage firm in which it has held a 15% stake for 15 years. The transaction, for cash and stock, would represent the biggest European takeover since 1980 for New York-based Marsh & McLennan, the world's largest insurance broker. It's also the first major sign of the long-awaited consolidation in the European insurance industry as the European Community Commission moves toward a single market by 1992

Společnost Marsh & McLennan Cos. **Uvedla**, že souhlasí s tím, aby získala zbytek společnosti Gradmann & Holler, přední západoněmeckou pojišťovací makléřskou firmu, ve které drží 15% podíl 15 let. Transakce za hotovost a akcie představuje největší evropský převzetí od roku 1980 pro Marsh & McLennan, největší světový pojišťovací makléř, se sídlem v New Yorku. Je to také první hlavní známka dlouho očekávané konsolidace v evropském pojistném průmyslu, jelikož Komise Evropského společenství **se** do roku 1992 směřuje k jednotnému trhu

Google Translate 2023

Marsh & McLennan Cos. said it agreed to acquire the rest of Gradmann & Holler, a leading West German insurance brokerage firm in which it has held a 15% stake for 15 years. The transaction, for cash and stock, would represent the biggest European takeover since 1980 for New York-based Marsh & McLennan, the world's largest insurance broker. It's also the first major sign of the long-awaited consolidation in the European insurance industry as the European Community Commission moves toward a single market by 1992

Společnost Marsh & McLennan Cos. uvedla, že souhlasila s akvizicí zbytku společnosti Gradmann & Holler, přední západoněmecké pojišťovací makléřské firmy, ve které drží 15% podíl již 15 let. Transakce za hotovost a akcie by představovala největší evropské převzetí od roku 1980 **pro newyorskou společnost Marsh & McLennan, největšího světového pojišťovacího makléře**. Je to také první hlavní známka dlouho očekávané konsolidace v evropském pojišťovacím průmyslu, **když** se Komise Evropského společenství posouvá směrem k jednotnému trhu do roku 1992.

Statistický strojový překlad

Pravděpodobnost vs. Relativní četnost

Příklad:

překlad předložky „in“ do francouzštiny:

3 možnosti – dans, à, de

Jak zjistit pravděpodobnost překladu?

Těžko.

Potřebujeme k tomu totiž obrovské množství událostí, neboť při dostatečně dlouhé sérii pokusů se relativní četnost jednotlivých výsledků blíží jejich pravděpodobnosti.

Pravděpodobnost tedy aproximujeme relativní četností.

Relativní četnost:

$f(E) = c(E)/N$ kde $c(E)$ je počet výskytů jevu (slova),
N celkový počet slov

Odhad pravděpodobnosti

Jednoduchá pravděpodobnost výskytu konkrétního slova v textu:

- máme 2 miliony slov v textu, slovo „**read**“ se v něm vyskytuje 720 krát

$$\Rightarrow p(\text{read}) \approx 720/2000000 = 0,00036$$

Překlad „**in**“:

Posbíráme 500 vět obsahujících překlad „**in**“ do francouzštiny

- 250 krát dans, 150 krát à, 100 krát de

- $p(\text{dans}) = 250/500 = 0,5$

- $p(\text{à}) = 0,3$

- $p(\text{de}) = 0,2$

Základní vzorce

Dva nezávislé jevy A a B:

$$p(A,B)=p(A)p(B)$$

Podmíněná pravděpodobnost (Bayesův vzorec) :

$$p(A|B) = \frac{p(B|A)p(A)}{p(B)}$$

Další důležité vzorce:

$$p(A,B)=p(A|B) p(B)=p(B,A)$$

$$p(A,B,C)=p(A|B,C)p(B|C)p(C) \text{ etc.}$$

Modelování jazyka

Hlavní úkol: **Předpovědět** následující slovo v běžném textu nebo promluvě.

Jak?

Pomocí podmíněné pravděpodobnosti na základě kontextu (historie) předpovídáme následující slovní tvar

$p(w|h)$ w – předpovídané slovo, h – historie, vše, co bylo dosud řečeno (napsáno)

Cíl: spočítat pravděpodobnost celé věty:

$$p(W) = p(\langle w_i \rangle_{i=1..n})$$

N-gramy

$$p(W) = p(\langle w_i \rangle_{i=1..n}) = p(w_n | \langle w_i \rangle_{i=1..n-1}) * p(w_{n-1} | \langle w_i \rangle_{i=1..n-2}) * \\ p(w_{n-2} | \langle w_i \rangle_{i=1..n-3}) * \dots * p(w_2 | w_1) * p(w_1)$$

Problém:

příliš dlouhá historie znamená nedostatek (řídkost) dat a obrovské nároky na výpočetní kapacitu => je nutné historii včas „useknout“

$n=3$ trigramový model

$$p(W) = p(w_3 | w_2 w_1) * p(w_2 | w_1) * p(w_1)$$

Kratší jsou bigramy ($n=2$), unigramy ($n=1$)

Vyhlazování

Problémem je **velikost dat**

Máme-li slovník (V) o 40000 slovech =>

- $|V|=40k$, **velikost modelu** = $|V|^3 = 6,4 \times 10^{13}$

- typická velikost trénovacích dat – stamiliony (10^8) slov

- příliš mnoho nulových pravděpodobností (**nenulová** pouze **jedna ze 100000 !**) – řídká data

- některé z nich ale zastupují existující kombinace

Řešení – nahradit nulovou pravděpodobnost nějakou velmi malou hodnotou (tím ale ztratíme schopnost rozlišovat opravdu neexistující kombinace)

Stručný úvod do statistického překladu

- Základní myšlenka – použít paralelní korpus jako trénovací množinu příkladů dobrého překladu
- Paralelní korpusy existují jak pro dvojice jazyků, tak i pro větší množiny (korpus dokumentů EU - Europarl)
- Klasický příklad – kanadský Hansard (A-F, trénovací data pro pokusy IBM v 90.letech, má 1.7 milionu vět)
- Inspiraci můžeme vysledovat až k Warenu Weaverovi, který v roce 1949 navrhoval použití kryptoanalytických metod na překlad
- Díky soustavnému růstu výpočetní síly a dostupnosti paralelních dat se statistický překlad stal donedávna převládající metodou, v posledních letech ustoupil neuronovým sítím

Metoda zašuměného kanálu

- Příklad – chceme překládat z F do A
- Hledáme pravděpodobnostní model $P(a|f)$, který vyjádří podmíněnou pravděpodobnost libovolné anglické věty a , máme-li francouzskou větu f . Trénovací korpus nám pomůže nastavit parametry
- Bayesův vzorec:
$$p(a|f) = \frac{p(f|a)p(a)}{p(f)}$$
- Tím jsme „obrátili“ směr překladu, budeme hledat dva modely: překladový model $P(f|a)$
jazykový model cílového jazyka $P(a)$
- Proč zašuměný kanál? Protože předstíráme, že jsme obdrželi větu „pokaženou“ přenosem přes nespolehlivý kanál a hledáme její správný originál.

Metoda zašuměného kanálu

- Jazykový model $P(A)$ může být trigramový model založený na mnohem rozsáhlejší korpusu cílového jazyka, řádově stamiliony slov
- Překladový model $P(F|A)$ je založen na mnohem menším paralelním korpusu (miliony slov)
- Důležité:
 - Překladový model budujeme v opačném směru.
 - Jazykový model odfiltruje nepodařené překlady, vyrovná chyby překladového modelu.
 - Jazykový model vybírá pouze „hezké věty,“ nemá vztah k originálu.
 - Hledání překladových hypotéz (**dekódování**) je obtížným problémem samo o sobě.

Příklad (Koehn and Knight)

Překlad ze španělštiny do angličtiny, možné překlady jsou založeny pouze na $P(\check{S} \mid E)$:

Que hambre tengo yo!

What hunger have $P(\check{S} \mid E) = 0.000014$

Hungry I am so $P(\check{S} \mid E) = 0.000001$

I am so hungry $P(\check{S} \mid E) = 0.0000015$

Have i that hunger $P(\check{S} \mid E) = 0.000020$

. . .

Přidáme jazykový model $P(E)$:

Que hambre tengo yo!

What hunger have $P(S|E)P(E) = 0.000014 \times 0.000001$

Hungry I am so $P(S|E)P(E) = 0.000001 \times 0.0000014$

I am so hungry $P(S|E)P(E) = 0.0000015 \times 0.0001$

Have i that hunger $P(S|E)P(E) = 0.000020 \times 0.00000098$

. . .

Evaluace systémů automatického překladu

metrika **BLEU** (Papineni, Roukos, Ward and Zhu, 2002):

Kandidát 1: It is a guide to action which ensures that the military always **obeys** the commands of the party.

Kandidát 2: It is to **insure the troops** forever **hearing** the **activity guidebook** that party **direct**.

Reference 1: It is a guide to action that ensures that the military will **forever** heed Party commands.

Reference 2: It is the guiding principle which guarantees the military forces always being under the command of the Party.

Reference 3: It is the practical guide for the army **always** to heed the directions of the **party**.

Přesnost překladu v n-gramech

Unigramová přesnost a kandidátů na správný překlad: **C/N**
kde **N** je počet slov v daném kandidátu, **C** je počet slov z tohoto kandidáta, které se vyskytují alespoň v jednom referenčním překladu.

V našem příkladu tedy:

Kandidát 1: 17/18

(pouze *obeys* chybí ve všech referenčních překladech)

Kandidát 2: 7/18

Modifikovaná N-gramová přesnost

Unigramovou přesnost je možné zobecnit na další n-gramy, postupně bereme dvojice, trojice a čtveřice.

Například pro kandidáty 1 a 2 platí bigramová přesnost:

$Přesnost_1(\text{bigram}) = 10/17$

$Přesnost_2(\text{bigram}) = 1/13$

BLEU - Celkové skóre

Penalizace za stručnost (Brevity penalty)

Míra založená pouze na počtu správných n-gramů by měla tendenci favorizovat krátké věty, jejichž všechny n-gramy by existovaly v referenčních překladech, přestože by referenční překlady byly podstatně delší – např. při překladu pouze části originálu. Proto je nutné výsledek upravit o číslo, které zachycuje rozdíl v délkách a penalizuje jej

Celkové skóre je tedy:

$$\text{BLEU} = \text{BP} * (p_1 p_2 p_3 p_4)^{1/4}$$

Tedy: Penalizace za stručnost vynásobená geometrickým průměrem n-gramové přesnosti pro $n=1..4$
Výsledkem je vždy číslo mezi 0 a 1

BLEU – Výhody a nevýhody

Výhody

- rychlý výpočet je důležitý pro ladění systému, pomůže rychle zjistit, zda se systém zlepšuje
- pokud je správně použita, je to relativně objektivní míra s vysokou korelací s lidským hodnocením
- je relativně levná
- stala se obecně přijímaným standardem

Nevýhody

- ačkoli by se neměla používat pro porovnávání různých systémů a odlišných jazykových párů, často se to děje
- získání dostatečného počtu referenčních překladů je drahé
- favorizuje statistické systémy, které se vůči ní ladí
- špatně zachycuje varianty, ať už slovosledné, lexikální, morfologické
- přeceňuje se, není tak univerzální, jak vypadá

More data is better data...

Impact on size of language model training data (in words) on quality of Arabic-English statistical machine translation system

