

Úvod do počítačové lingvistiky (pro informatiky)

Úvod do Úvodu

Co je počítačová lingvistika?

Obor, zabývající se formálním popisem vlastností přirozených jazyků a jejich automatickým zpracováním (vytváření automatických systémů, modelujících užívání přirozeného jazyka).

Je to mezní obor, využívající výsledků (a také přispívající k dalšímu rozvoji):

- teoretické lingvistiky
- teoretické informatiky (viz Chomského hierarchie jazyků)
- umělé inteligence
- psychologie
- logiky
- matematiky (statistiky)

Jiné názvy: matematická lingvistika, algebraická lingvistika, statistická lingv.

PL x NLP

Počítačová lingvistika – Computational Linguistics (PL)

Tradiční obor, jehož hlavním cílem je **popis vlastností a chování přirozených jazyků** prostřednictvím matematických a informatických metod. Výzkum je primárně veden snahou pochopit a popsat, jak přirozené jazyky fungují.

Počítačové zpracování přirozeného jazyka – Natural Language Processing (NLP)

Moderní obor zaměřený primárně na **aplikace metod strojového učení na jazyková data** (korpusy apod.). Nejviditelnějším úspěchem NLP jsou v současné době velké jazykové modely, ale značný pokrok byl dosažen i v automatickém překladu, extrakci informací, identifikaci pojmenovaných entit, analýze sentimentu apod. Úspěšné aplikace ale nepřispívají k pochopení struktury a funkce přirozených jazyků.

Oblasti (počítačové) lingvistiky

- Morfologie (tvarosloví)
- Syntaxe (skladba)
- Sémantika (význam)
- Formalismy (syntaktické)
- Korpusová lingvistika
- Statistická lingvistika (dříve kvantitativní, nyní modeluje užívání jazyka)
- Strojový (automatický) překlad
- Rozpoznávání a generování mluvené řeči
- Vyhledávání informací v textu
- Dialogové systémy
- ...

Problémy významové ekvivalence

- ČVUT má budovy nedaleko Vítězného náměstí.
ČVUT má budovy nedaleko Kulaťáku.
- Karel prodává auta.
Od Karla se kupují auta.
- Nakrájel salám na pět kusů.
Nakrájel ze salámu pět kusů.
- Na Moravě se mluví česky.
Česky se mluví na Moravě.

Víceznačnost a vágnost jazyka

- Bramborové knedlíky a švestkové knedlíky
- Kritika brazilského delegáta byla ostrá.
- V místnosti stojí zelené skříně a židle.
- Na recepci se dostavil i ředitel banky roku.
- Vysoká škola lesnická v Trutnově otevřela novou fakultu.
- Často loví tlouště na višni.
- Když slepice málo snáší, tak se vejce špatně shání.
- Páry vycházejí z lesa.
- Včera jsem viděl Frantu v tramvaji.
- Dědeček se rozložil na gauči.
- Závodnice se před závodem se soupeřkami oddávala sexu.
- Dálnice z Žiliny do Bratislavy postavená Ruskem stála 10 miliard.

Příklady z tisku

- Loprais upustil kola a ujížděl.
- Padl návrh vyhodit Čunka.
- Garant programu CŽV bude jmenován děkanem.
- Pešán se nestačil divit, na hotelu čekali jeho milenky.
- Na trase C spadl člověk do kolejiště metra, nahradí ho autobusy
- Zeman plísnil politiky
- Otec Emmons bude trénovat Australany.
- Honila hluchého psa, zasedl ji velbloud. Žena v USA si pomohla kousnutím do varlat.
- Padlým námořníkům se znovu rozsvítilo
- V hotelu Corrado se za jeho nejslavnější éry scházely prostitutky. Často tam bydlely špičky ČSSD jako Miloš Zeman, Jiří Paroubek nebo Petr Benda.
- Na českých silnicích umírá více lidí než ve zbytku EU, hůř jsou na tom jen v Polsku.

DĚTI ZA KORUNU



aquapalace
praha




více na: www.aquapalace.cz



Muž půl roku onanoval ženě před dveřmi. Až nyní ho policisté dohonili

17.05.2018





Maso z našeho řeznictví



OCHUTNEJ
našeho
ŘEZNÍKA



*Tady jsem
správně!*

Příklady z tisku (2)

- Inspektor Barnaby řeší případ vraždy otrávením úředníka sociální správy.
- Pastrňák pomohl k výhře Bostonu gólem, kterým překonal Holíka
- Džihádista chtěl ve Vídni odpálit nádraží, soud mu ale dal další šanci.
- Muž venčící psa, který v Praze pokousal dítě, se přihlásil na policii.
- Miss World bude kvůli islámu bez plavek.
- Dítěti uvízla ruka v kanálu, hasiči ho rozřezali.
- Uštknutí zmijí je vzácné, ale když kousne dítě, může jít o život.
- V reakci na americký útok, při němž zemřel Kásim Sulejmání, velitel iránských jednotek Kuds, exministr zahraničí a poslanec Karel Schwarzenberg prohlásil, že Trumpovy skutky jsou zločinné a překračují mezinárodní právo.
- Králem Tour je počtvrté Froome, dorazil se šampaňským.
- V lese viděli kolemjdoucí mrtvolu.
- Sarah Palinová řekla Ne, Obamovi se nepostaví.

Reklamní vložka

Projekt LINDAT/CLARIN

Otevřený digitální repozitář sloužící k uchování a sdílení dat a nástrojů v oblasti zpracování přirozených jazyků.

<https://lindat.mff.cuni.cz>

Spolupráce:

ÚFAL MFF UK

Katedra kybernetiky ZČU

Ústav pro jazyk český AV ČR

Centrum pro zpracování přirozeného jazyka MUNI

MŠMT



LINDAT/CLARIN



- **Perzistentní identifikátory**
Garantují, že k danému datovému souboru nebo nástroji půjde i v budoucnu vždy přistupovat pod stejným ID
- **Dlouhodobá a bezpečná úschova (20 let a více)**
- **Podpora volby licencí**
Speciální nástroj, umožňující autorům vybrat adekvátní licenci i bez rozsáhlých právních znalostí
- **Nástroje a data pro mnoho jazyků**
K dnešnímu dni v LINDATu naleznete 379 jazyků a nářečí
- **Prohledávání velkého množství různorodých korpusů**
Jazykové korpusy jsou primárním zdrojem dat jak pro tradiční lingvistiku, tak pro strojové učení. Aby je bylo možno plně využívat, měly by mít standardní podobu.

LINDAT/CLARIN



- **API rozhraní pro programátory**
Potřebuje-li uživatel využít některé nástroje ve svých projektech, může je do nich (pod vhodnou licencí) zakomponovat.
- **Dema pro běžné uživatele**
Celá řada nástrojů je volně k dispozici na stránkách LINDATu pro vyzkoušení nebo jednorázové využití
- **Spousta užitečných aplikací**
Morfologická analýza a značkování, Parsery, systémy automatického překladu, extrakce klíčových slov, rozpoznávání pojmenovaných entit ...
- **Licence dovolují prakticky volné použití pro nekomerční účely**
- **Korektní citace článků i dat**
Na přípravě jazykových korpusů se obvykle podílejí celé týmy lidí, ale autory odborných článků o korpusech bývají pouze vedoucí týmů – LINDAT umožňuje citovat i datové soubory, nejen články

Morfologie

Prehistorie morfologie

Morfologie je asi nejstarším odvětvím lingvistiky. První počátky se datují 4.stoletím př.n.l., kdy indický lingvista [Pānini](#) formuloval 3 959 pravidel morfologie sanskrtu v díle [Ashtadhyayi](#). Jeho popis se blížil tzv. složkové gramatice.

Ashtadhyayi je nejstarší známou gramatikou sanskrtu a zároveň také nejstarší známou prací deskriptivní lingvistiky, generativní lingvistiky, a společně s prací jeho bezprostředních předchůdců ([Nirukta](#), [Nighantu](#), [Pratishakyas](#)) prakticky znamená začátek lingvistiky jako vědního oboru.

Řecko-římská gramatická tradice se také zabývala morfologickou analýzou, protože stará řečtina a latina patřily mezi jazyky s bohatým skloňováním a časováním (tzv. flektivní jazyky).

Panini měl také značný vliv na moderní lingvistiku, otec strukturalismu, [Ferdinand de Saussure \(1857 – 1913\) \(Course in General Linguistics\)](#), byl profesorem sanskrtu.


Morfologie


Předmětem morfologie je studium vnitřní struktury slov.

Lexikologie - slova jsou studována jako jednotky slovní zásoby

Lexikografie – sestavování slovníků

Základní jednotkou studia morfologie je **morfém** – nejmenší znaková jednotka jazyka nesoucí význam

Morfém  **lexikální** – nese význam slova jako takového
gramatický – určuje gramatickou roli slovního tvaru



Další pojmy

Morfologie studuje způsoby **skloňování** (deklinace) a **časování** (konjugace).

Tvaroslovné **dublety** – odlišné slovní tvary mající stejnou gramatickou funkci (na hradě/o hradu, o balíčcích/balíčkách apod.)

Homonymní tvary - stejné slovní tvary odvozené od dvou nebo více slovních základů (žena, tři, hnát, stát, už apod.)

Alternace – změna hlásek uvnitř kmene

vůz – vozu; švec – ševce; prkno - prken

Autosémantická (plnovýznamová) slova

Synsémantická (pomocná) slova

Morfologická typologie jazyků

Příklad: Způsob vyjádření rozdílu mezi jednotným a množným číslem v různých jazycích:

1. Nulový rozdíl: **Japonština** *ringo* 'jablko', pl. *ringo* nebo *isu* 'židle', pl. *isu*
2. Funkční slovo: **Tagalog** *bato* 'kámen', pl. *mga bato*
3. Afixace: **Tureština** *ev* 'dům', pl. *ev-ler*; **Swahilština** *m-toto* 'dítě', pl. *wa-toto*
4. Zvukový rozdíl: **Angličtina** *man*, pl. *men*; **Arabština** *rajulun* 'muž', pl. *rijālun*
5. Reduplikace: **Malajština** *anak* 'dítě', pl. *anak-anak*


Dalším rozdílem je to, že v některých příkladech každé slovo sestává z jednoho morfému, v jiných je více než jeden morfém.

Pokud na mě počkáte, půjdu s vámi.

Čínština: nǐ děng wǒ, wǒ jiù gēn nǐ qù.
2SG čekat 1SG 1SG pak s 2SG jít

Inuitština: Utaqqi-gu- vi- nga, aulla-qati- gi- niaq- pa- git
čekat pokud 2SG 1SG jít partner mít budoucí ujištění 1SG/2SG

Morfologická typologie jazyků



Izolační: vietnamština, čínština

Flektivní: latina, stará řečtina, slovanské jazyky

Aglutinační: maďarština, japonština

Polysyntetické: eskymácké a indiánské jazyky

Žádný moderní jazyk ale obvykle nemá výhradně čisté vlastnosti jednoho z těchto typů, vždy se najdou výjimky typicky způsobené kontaktem (vzájemným ovlivněním) s jinými jazyky.

Přístupy ke zpracování morfologie

Morfologie založená na **morfémech**

- **vidí slovo jako řetízek morfémů**, jako korálky na niti

Toto pojetí nejvíce vyhovuje aglutinačním jazykům:

turečtina (podle Kemala Oflazera):

uygar+laş+tır+ama+dık+lar+ımız+dan+miş+siniz+casına

„(chováš se) jako bys patřil mezi ty, které jsme nedokázali civilizovat“

Morfologie založená na **lexémech**

- **vidí slovo jako výsledek aplikace pravidel**, která slovo mění a tím vytváří nový slovní tvar (viz Two-Level Morphology)

Morfologie založená na **slovech (vzorech)**


- **centrální roli mají vzory**. Pokud máme základní tvar a známe, ke kterému vzoru slovo patří, dokážeme vygenerovat všechny jeho tvary. Tento přístup je vhodný i tam, kde předchozí dva selhávají, např. tam, kde jeden morfém reprezentuje více gramatických kategorií (např. 3.os. čísla jednotného rodu ženského).

Two-Level Morphology

Systém zpracování morfologie vyvinutý Lauri Karttunenem a Kimmo Koskeniemiem na začátku 80.let.

Jednalo se o první obecný model zpracování morfologie přirozeného jazyka. Byl založen na **konečněstavových automatech**, pro každý jazyk bylo nutné vytvořit **slovník a pravidla**, společný byl mechanismus morfologie.

Tradiční počítačové zpracování morfologie se orientovalo na generování výsledných tvarů slov z nějakého tvaru základního a nebralo příliš v úvahu, že opačný směr (analýza) může být víceznačný. Uplatnění pravidel bývalo **sekvenční**.




Two-Level Morphology

2 úrovně – lexikální a povrchová

Základní myšlenky:


- pravidla se aplikují paralelně, nikoli sekvenčně



- podmínky se mohou vztahovat k jedné z úrovní nebo k oběma zároveň



- lexikální vyhledávání (trie, letter tree) a morfologická analýza probíhají současně



Morfologie založená na vzorech

Jednoduchý ilustrativní algoritmus morfologické analýzy:

Potřebujeme:

- slovník kmenů slov s informací o jejich vzoru
- seznam koncovek, z nichž každá s sebou nese seznam **vzorů, rodů, čísel a pádů (osob)** – např.:
ENA: **Tiskne**(F(S,1,2,3),N(P,3)); **Nese**(F(S,1,2,3),N(P,3)),
Prosí(F(S,1,2,3),N(P,3)) nebo
A: **Pán**(M,/,G(S),A(S),/), **Předseda**(M,N(S),),**Hrad**(I,G(S)),**Žena**(F,N(S)),
Město(N,G(S),N(P),A(P)),**Otcův**(M(G(S),A(S)),I(G(S)),F(N(S)),N(G(S),N(P),A(P)))

Poznámka:

Pro jednoduchost je vynechána koncovka – **NA**, kterou bychom také museli brát v úvahu, ale tento příklad by zbytečně komplikovala – patří totiž hned k několika slovesným vzorům.

Morfologie založená na vzorech

Algoritmus

- Pokud se v textu vyskytne např. slovní tvar **KAČENA**, odtrhneme všechny možné koncovky a dostaneme **KAČEN**, **KAČE** a **KAČ**. Pouze první z těchto kmenů je ve slovníku s informací, že se jedná o podstatné jméno podle vzoru ŽENA, jiný kmen ve slovníku není.
- Ze seznamu u příslušné koncovky pak vybereme pouze čísla a pády uvedené pro vzor ŽENA, tedy **F,N(S)**
- Výsledkem je:

Kačena(podstatné jméno, rod ženský, 1.pád čísla jednotného)

Poznámky:

- Výsledek morfologické analýzy bývá víceznačný, ať již co do kombinace čísel a pádů (osob), nebo dokonce i co do kmenů.
- Tento zjednodušený algoritmus neřeší změny uvnitř kmene u jednotlivých slovních tvarů, o ty je třeba algoritmus obohatit.

Morfologické značky (Part of Speech Tags)

V kontextu angličtiny jako spíše izolačního jazyka jsou morfologické značky chápány jako identifikátory všech morfologických vlastností slovního tvaru, nikoli jako kombinace jednotlivých kategorií jako **slovní druh, rod, číslo, pád, stupeň** apod. V angličtině se nejčastěji používá termín **Part-Of-Speech (POS)**.

POS značky dělíme na dva základní typy – **otevřenou** a **uzavřenou třídu** slovních druhů. **Uzavřené** slovní druhy se v podstatě dají popsat výčtem (předložky, pomocná slova, spojky apod.) Otevřené slovní druhy výčtem popsat nelze (podstatná a přídavná jména, slovesa, příslovce, apod.), protože jejich seznam není nikdy kompletní, jazyk se vyvíjí.

Tagset (sada používaných značek) se liší nejen pro různé jazyky, ale také pro různé lingvistické teorie nebo aplikace v rámci jednoho jazyka. Dva velmi známé korpusy angličtiny používají různé sady značek: 45 pro PennTreebank a 87 pro Brown corpus.

Pokud bychom tímto způsobem přistupovali k češtině, bylo by různých značek určitě více než 1000.

Morfologické značky

Příklad systému značek v projektu Universal Dependencies, iniciativě, která má cíl standardizovat morfologická a syntaktická lingvistická data:

	Tag	Description	Example
Open Class	ADJ	Adjective: noun modifiers describing properties	<i>red, young, awesome</i>
	ADV	Adverb: verb modifiers of time, place, manner	<i>very, slowly, home, yesterday</i>
	NOUN	words for persons, places, things, etc.	<i>algorithm, cat, mango, beauty</i>
	VERB	words for actions and processes	<i>draw, provide, go</i>
	PROPN	Proper noun: name of a person, organization, place, etc..	<i>Regina, IBM, Colorado</i>
	INTJ	Interjection: exclamation, greeting, yes/no response, etc.	<i>oh, um, yes, hello</i>
Closed Class Words	ADP	Adposition (Preposition/Postposition): marks a noun's spacial, temporal, or other relation	<i>in, on, by, under</i>
	AUX	Auxiliary: helping verb marking tense, aspect, mood, etc.,	<i>can, may, should, are</i>
	CCONJ	Coordinating Conjunction: joins two phrases/clauses	<i>and, or, but</i>
	DET	Determiner: marks noun phrase properties	<i>a, an, the, this</i>
	NUM	Numeral	<i>one, two, 2026, 11:00, hundred</i>
	PART	Particle: a function word that must be associated with another word	<i>'s, not, (infinitive) to</i>
	PRON	Pronoun: a shorthand for referring to an entity or event	<i>she, who, I, others</i>
	SCONJ	Subordinating Conjunction: joins a main clause with a subordinate clause such as a sentential complement	<i>whether, because</i>
Other	PUNCT	Punctuation	<i>; , ()</i>
	SYM	Symbols like \$ or emoji	<i>\$, %</i>
	X	Other	<i>asdf, qwfg</i>

Česká morfologie

Vyvíjena od r.1989 zejména prof.Hajičem. Využívá pozičních značek, každá pozice má svůj jednoznačně určený význam. Značky jsou 15 místné, ovšem rozeznává se pouze 13 kategorií, dvě pozice jsou rezervní:

Category	# of values	Example(s)
POS	10	N (noun), Z (punctuation)
SUBPOS	75	P (personal pron.), U (possessive adj.)
GENDER	8	I (masc. inanimate), X (any), - (N.A) -----
NUMBER	4	P (plural), D (dual)
CASE	9	1 (nominative), 6 (locative)
POSSGENDER	4	M (masc. animate), F (feminine) ↓
POSSNUMBER	3	S (singular), P (plural)
PERSON	5	1 (first), ...
TENSE	4	P (present), M (past)
GRADE	5	3 (superlative)
NEGATION	3	A (affirmative), N (negative)
VOICE	3	A (active), P (passive)
VAR	11	1 (1 st variant), 6 (colloq. style), 8 (abbrev.)

Česká morfologie

- Značka: 13 kategorií

– Příklad: AAFP3-----3N-----

Adjective

Regular

Feminine

Plural

Dative

no poss. Gender

no poss. Number

no person

no tense

superlative

negated

no voice

reserve1

reserve2

base var.

Ex.: nejnezajímavější
“(to) the most uninteresting”

- Lemma: jednoznačný identifikátor
 - stát/slov. -> stát-1, stát/subst. -> stát-2
 - šel -> jít

Česká morfologická analýza - příklad

Vstup:

Prezident rezignoval na svou funkci.

Výstup:

```
<csts>
<f cap>Prezident<MMI>prezident<MMt>NNMS1-----A----
<f>rezignoval<MMI>rezignovat_:T<MMt>VpYS---XR-AA---
<f>na<MMI>na<MMt>RR--4-----<MMt>RR--6-----
<f>svou<MMI>svůj-1_^(přivlast.)<MMt>P8FS4-----1<MMt>P8FS7-----1
<f>funkci<MMI>funkce<MMt>NNFS3-----A----<MMt>NNFS4-----A----
<MMt>NNFS6-----A----
<D>
<d>.<MMI>.<MMt>Z:-----
</csts>
```

Činnosti využívající morfologii

Morfologická analýza – výsledkem je seznam lemmat a značek popisujících jednotlivé kombinace gramatických kategorií spjatých s daným vstupním slovním tvarem.

Morfologické značkování (tagging) – proces výběru jediné správné značky v daném kontextu (statistické metody).

Lemmatizace – proces výběru (správného) základního tvaru, ze kterého byl odvozen daný vstupní tvar. Je to klíčová operace pro vyhledávání v textech.

Stemming – odříznutí koncovky, na rozdíl od lemmatizace je základním tvarem kmen slova. Populární je tzv. Porterův stemmer.

Generování – proces výběru správného slovního tvaru, pokud známe lemma a příslušnou kombinaci gramatických kategorií.

Zajímavý experiment: Částečná morfologická desambiguace

Částečná morfologická **desambiguace založená na pravidlech** (Oliva, Petkevič, 2001) – pomocí spolehlivých pravidel redukuje značky u jednotlivých slovních tvarů **na výstupu z morf. analýzy**, odstraňuje nevhodné, ponechává všechny, které nelze spolehlivě odstranit.

Struktura pravidel

Dvě části – **popis kontextu** a **akce** (odstranění nevhodných značek nebo potvrzení správné značky)

Pravidla byla tvořena **ručně** a testována na morfologicky anotovaném korpusu, aby bylo dosaženo jejich prakticky 100% správnosti. Jsou na sobě vzájemně nezávislá (teoretický základ jsou tzv. restartovací automaty).

Cílem bylo snížit počet variant značek, aby následné statistické značkování mělo lehčí úlohu.

Výsledek: Došlo k nepatrnému zlepšení celkového výsledku (z 95,16% na 95,38%), což v podstatě potvrdilo, že **statistický přístup** založený na anotovaném korpusu se **dokáže správně rozhodovat** velmi podobně **jako lingvistický expert**.

Částečná morfologická desambiguace

Vstup	Lemma	Značka
Zítra	zítra	Db-----
se	se_^(zvr._zájm./částice)	P7--4-----
	s-1	RV--2-----
	s-1	RV--7-----
hraje	hrát	VB-S---3P-AAI--
	hrát	VeYS-----A-I--
liga	liga	NNFS1-----A----
.	.	Z:-----

Mezi předložkou a jejím řídícím podstatným jménem nemůže být sloveso
=> “se” v tomto kontextu nemůže být předložkou.

Text

Morfologická analýza

Značkování


Fantastickým	fantastický AAFP3----1A---- AAIP3----1A---- AAIS6----1A---7 AAIS7----1A---- AAMP3----1A---- AAMS6----1A---7 AAMS7----1A---- AANP3----1A---- AANS6----1A---7 AANS7----1A----	fantastický AAIS7----1A----
finišem	finiš NNIS7----A----	finiš NNIS7----A----
si	být VB-S---2P-AA--7 se_ ^ (zvr._zájmeno/částice) P7-X3-----	se_ ^ (zvr._zájmeno/částice) P7-X3-----
však	však J^-----	však J^-----
Neumannová	Neumannová_;S NNFS1----A---- NNFS5----A----	Neumannová_;S NNFS1----A---- -
doběhla	doběhnout_:W VpQW---XR-AA—1	doběhnout_:W VpQW---XR-AA-- 1
pro	pro-1 RR--4-----	pro-1 RR--4-----
vytoužené	vytoužený_ ^ (*3it) AAFP1----1A---- AAFP4----1A---- AAFP5----1A---- AAFS2----1A---- AAFS3----1A---- AAFS6----1A---- AAIP1----1A---- AAIP4----1A---- AAIP5----1A---- AAMP4----1A---- AANS1----1A---- AANS4----1A---- AANS5----1A----	vytoužený_ ^ (*3it) AANS1----1A-- -- (AANS4----1A----)
olympijské	olympijský AAFP1----1A---- AAFP4----1A---- AAFP5----1A---- AAFS2----1A---- AAFS3----1A---- AAFS6----1A---- AAIP1----1A---- AAIP4----1A---- AAIP5----1A---- AAMP4----1A---- AANS1----1A---- AANS4----1A---- AANS5----1A----	olympijský AANS1----1A---- (AANS4----1A----)
zlato	zlato NNNS1----A---- NNNS4----A---- NNNS5----A----	zlato NNNS1----A---- (NNNS4-- ---A----)
.	. Z:-----	. Z:-----

Značkování

(Part-of-speech tagging)

- Výběr nejpravděpodobnější morfologické značky pro daný slovní tvar
- Neřešíme pro jednotlivé slovní tvary izolovaně, ale hledáme nejpravděpodobnější posloupnost značek pro celou větu $\hat{t}_1^n = \operatorname{argmax}_{t_1^n} P(t_1^n | w_1^n)$
- Použitím Bayesova vzorce $P(x|y) = \frac{P(y|x)P(x)}{P(y)}$ dostaneme
$$\hat{t}_1^n = \operatorname{argmax}_{t_1^n} \frac{P(w_1^n | t_1^n) P(t_1^n)}{P(w_1^n)} = \operatorname{argmax}_{t_1^n} P(w_1^n | t_1^n) P(t_1^n),$$
 protože $P(w_1^n)$ je pro všechny posloupnosti značek stejné.
- Nutná zjednodušení – pravděpodobnost výskytu slovního tvaru závisí pouze na jeho značce; a pravděpodobnost výskytu značky závisí pouze na předchozí značce
- Po úpravě $\hat{t}_1^n \approx \operatorname{argmax}_{t_1^n} \prod_{i=1}^n P(w_i | t_i) P(t_i | t_{i-1})$

Příklad Markovova řetězce



Markovův řetězec pro změny počasí. Startovní pravděpodobnosti: $p(HOT) = 0.1$, $p(COLD) = 0.2$, $p(WARM) = 0.7$,

Markovův řetězec je určen svou strukturou, přechody mezi stavy a startovním a koncovým stavem.

Skryté Markovovy modely

Hidden Markov Models - HMM

- Standardní metoda analýzy řad (posloupností událostí v čase) na základě kontextu (řečový signál, posloupnost morfologických značek v textu apod.)
- Posloupnost rozhodnutí, která jsou na sobě závislá
- Markovova hypotéza – kontext je možno zkrátit na délku, která je spočítatelná (bigramy, trigramy)
- Slovo „skryté“ reprezentuje fakt, že některé vlastnosti posloupnosti nejsou pozorovatelné (ve větě vidíme slova, nikoli morfologické značky, které jim přiřazujeme)
- Jedná se v podstatě o **stochastický konečný automat**.

Skryté Markovské Modely (HMM)

Formálně se skládají z následujících komponent:

- Množina N **stavů** $Q = q_1 q_2 \dots q_N$
- **Matice přechodových pravděpodobností** A , kde každé a_{ij} reprezentuje pravděpodobnost přesunu ze stavu i do stavu j ,
 $\sum_{j=1}^n a_{ij} = 1 \quad \forall i$
- Posloupnost **pravděpodobností pozorování (observation likelihoods)** $B = b_i(o_t)$, také nazývané **emisními pravděpodobnostmi (emission probabilities)**, z nichž každá reprezentuje pravděpodobnost pozorování o_t (slov ze slovníku $V = v_1, v_2, \dots, v_V$) ve stavu q_i
- **Počáteční distribuci pravděpodobností** nad stavy. π_i je pravděpodobnost, že Markovský řetězec odstartuje ve stavu i . Některé stavy j mohou mít $\pi_j = 0$, což znamená, že se nemůže jednat o počáteční stavy. Také platí $\sum_{i=1}^N \pi_i = 1$


HMM dostává na **vstup** $O = o_1 o_2 \dots o_T$: posloupnost T pozorování, z nichž každé pochází ze slovníku V .

Tři základní úlohy s HMM

1. **Rozpoznávání** (ohodnocení) statistického modelu (dynamické programování, v angl. literatuře Forward-backward algoritmus). Jsou dány parametry HMM, cílem je spočítat pravděpodobnost, že je pozorována posloupnost X . Použití: např. rozpoznávání obrázků (reg. značek aut)
2. **Dekódování**, neboli hledání nejpravděpodobnější posloupnosti skrytých stavů (Viterbiho algoritmus, dynamické programování). Je dán statistický model a posloupnost pozorování, cílem je najít nejpravděpodobnější posloupnost skrytých stavů.
3. **Učení** statistického modelu (Baum-Welshův algoritmus). Je dána struktura modelu (počet skrytých stavů) a trénovací množina. Cílem je najít parametry modelu, tedy pravděpodobnosti přechodů mezi stavy a pravděpodobnosti jednotlivých prvků posloupnosti.

Dekódování

- Viterbiho algoritmus – v podstatě hledání nejkratší cesty v grafu
- Orientovaný graf s hranami orientovanými zleva doprava. Počátečním vrcholem je α a cílovým β , ohodnocení hran odpovídá pravděpodobnosti přechodu
- Schéma pro skryté stavy A,B a C a pozorování 0,1,2 a 3



Příklad POS značkování

„Janet will back the bill“ (Příklad je zkopírován z knihy Speech and Language Processing, Daniel Jurafsky & James H. Martin, 2024)

Přechodová matice A:

	NNP	MD	VB	JJ	NN	RB	DT
<s>	0.2767	0.0006	0.0031	0.0453	0.0449	0.0510	0.2026
NNP	0.3777	0.0110	0.0009	0.0084	0.0584	0.0090	0.0025
MD	0.0008	0.0002	0.7968	0.0005	0.0008	0.1698	0.0041
VB	0.0322	0.0005	0.0050	0.0837	0.0615	0.0514	0.2231
JJ	0.0366	0.0004	0.0001	0.0733	0.4509	0.0036	0.0036
NN	0.0096	0.0176	0.0014	0.0086	0.1216	0.0177	0.0068
RB	0.0068	0.0102	0.1011	0.1012	0.0120	0.0728	0.0479
DT	0.1147	0.0021	0.0002	0.2157	0.4744	0.0102	0.0017

<s> je počáteční symbol, příklad přechodové pravděpodobnosti:
 $P(VB|MD)=0.7968$

Příklad POS značkování

„Janet will back the bill“

Pravděpodobnosti pozorování B :

	Janet	will	back	the	bill
NNP	0.000032	0	0	0.000048	0
MD	0	0.308431	0	0	0
VB	0	0.000028	0.000672	0	0.000028
JJ	0	0	0.000340	0	0
NN	0	0.000200	0.000223	0	0.002337
RB	0	0	0.010446	0	0
DT	0	0	0	0.506099	0


NNP je vlastní jméno, MD modální sloveso, VB sloveso, JJ přídavné jméno, NN hromadné podst. jméno nebo podst. jm. v singuláru, RB příslovce, DT člen

Cílem je odhalit správnou posloupnost značek:


Janet/NNP will/MD back/VB the/DT bill/NN

Viterbiho algoritmus pro značkování

- Konkrétní příklad pro větu „Janet will back the bill“



Zvětšený výřez HMM



Kontrola překlepů

Eye have a spelling chequer,
It came with my Pea Sea.
It plane lee marks four my revue
Miss Steaks I can knot sea

Požadavky:

1. Musejí být nalezeny všechny překlepy a nalezené musejí být opraveny
2. Musejí být přezkoušeny kontextové podmínky korigované verze
3. Slova, která systém nezná, by neměla být hlášena jako chyby
4. Systém by neměl dávat falešná chybová hlášení
5. Korektura musí být co nejvíce automatická
6. Čas zpracování musí být velmi krátký

Tyto požadavky je v praxi velmi obtížné splnit najednou.

Malá odbočka

Měření úspěšnosti experimentů

- Dvě základní míry – **Precision** (přesnost) a **Recall** (úspěšnost)
- **Precision** $P = \frac{\text{Počet správně zachycených chyb}}{\text{Celkový počet chybových hlášení}}$
- **Recall** $R = \frac{\text{Počet správně zachycených chyb}}{\text{Celkový počet chyb v textu}}$
- Obě míry se pohybují mezi 0 a 1, v experimentálních systémech se je snažíme vybalancovat
- Při kontrole překlepů je velmi silná preference přesnosti, úspěšnost je méně podstatná
- Sjednocením obou měr je tzv. **F-measure**:

$$F = \frac{2PR}{P + R}$$

Kontrola překlepů

2 základní metody

1. Porovnávání řetězců se slovy ve slovníku

- buď seznam všech možných slovních tvarů daného jazyka (wordlist)
- nebo slovník lemmat + morfologická analýza

Výhoda: Spolehlivé a jednoduché

Nevýhoda: pomalé, náročné na kvalitu slovníku, na místo, nerozezná chybná slova od neznámých, každé zlepšení musí zařídit autor nebo uživatel

2. Srovnávání skupin znaků (dvojice, trojice,...), hledání nedovolených kombinací znaků

Výhoda: nezávislé na slovníku, rychlé

Nevýhoda: velmi neúplné, i řada chybných slov se skládá z vhodných kombinací znaků

Kontrola překlepů

Nedílnou součástí nástroje je i nabízení oprav uživatelům. Je nutné nabízet:


- pouze relevantní opravy
- relativně omezené množství (nejlepších) oprav => nutnost uspořádání nabídek podle jejich relevance

Možná vylepšení základních metrik pro nabízení oprav:

- vzít v úvahu okolnosti vzniku chyb (blízké klávesy apod.)
- zohlednit statistiku chyb
- zohlednit možné pravopisné chyby (mně x mě, jsem x jsme)
- heuristika na oddělení chyb a neznámých slov
- zapojení syntaxe a sémantiky
- pracovat s kontextem (porovnávat s korpusy apod.)

Kontrola překlepů

Komunikace s uživatelem při nabízení oprav



Pro měření vzdálenosti nabízených řešení potřebujeme vhodnou metriku

Nejjednodušší – Levenshteinova editační vzdálenost

- Vzdálenost mezi dvěma řetězci se měří jako minimální počet elementárních operací, které transformují jeden řetězec na druhý
- vložit, odstranit, přepsat, vyměnit pozici dvou sousedních znaků

Kontrola překlepů

Komerční řešení

- Místo složitých heuristik se k omezení množství nabízených správných tvarů používá Levenshteinova vzdálenost řetězců – počet elementárních operací (vlození, odstranění, záměna a přehození) nutných na to, aby se z jednoho řetězce stal druhý.
- Výrazně se upřednostňuje přesnost (nenalezené chyby stejně autor nevidí) a rychlost.
- Teprve kontrola prováděná na pozadí způsobila masové rozšíření kontroly překlepů, uživatel nechce být zbytečně rušen.
- Uživatelsky definované slovníky nemají zabudovanou morfologii, je třeba do nich vkládat všechny tvary => ve spojení s kontrolou na pozadí prakticky nemají význam
- Omezená možnost dalšího rozvoje tradičních metod, vylepšení jdou směrem k většímu uplatnění kontextu.

Kontextové metody kontroly překlepů

Existují určité typy překlepů, které nelze odhalit pouze s pomocí slovníku:

weather/whether, **peace/piece**, **form/from**, **there/their**

Tyto chyby jsou mnohdy na pomezí mezi překlepy a gramatickými chybami. Některé z nich mohou být zachyceny dobrým nástrojem na kontrolu gramatické správnosti, např. **man/men** nebo v češtině **jsem/jsme** .

Moderní komerční nástroje kontroly překlepů pro angličtinu (MS Word, Grammarly apod.) obsahují kontroly, které berou v úvahu kontext.

Spelling checkery využívající kontext typicky používají statistické metody nebo metody strojového učení. Dívají se na více či méně vzdálený kontext. Kvalita jejich výsledků je do značné míry ovlivněna velikostí tréninkových dat a podobností tréninkových dat a vstupního textu.

Příklad kontextového spellcheckeru I.

Ghotit (www.ghotit.com) se zaměřuje na dyslektiky, dysgrafiky a nerodilé mluvčí. Tvrdí, že dokáže zkontrolovat následující věty:

On uv mie nayburs iz a wich. I now bekuz she kam at me wif a nif.

One of my neighbors is a witch. I know because she came at me with a knife.

Cdnuolt blveiee taht I cluod aulacly uesdnatnrd waht I was rdanieg.

Couldn't believe that I could actually understand what I was reading.

Amzanig huh yaeh and I awlyas tghuhot slpeling was ipmorantt.

Amazing how you and I always thought spelling was important.

Ale zcela selhává při kontrole úvodní básničky:

Eye **have** a spelling **chequer**, it came with my Pea Sea. It plane lee marks four my revue **Miss** Steaks I can knot sea.

Například nabízí **has** nebo **halve** místo **have** .

Příklad kontextového spellcheckeru II.

WinSpell (Versoworks Pty Ltd.) využívá metody strojového učení.

- V prvním kroku identifikuje tzv. **záměnnou množinu** (confusion set), což je množina výrazů, které jsou navzájem snadno zaměnitelné. Autoři k tomu využívají slovník Random House Dictionary.
- Aby bylo možné rozlišit jednotlivé výrazy ze záměnné množiny, berou se v úvahu **kolokace** a slova v **kontextu** (kolokace do vzdálenosti 2 a kontext do vzdálenosti 10 slov). Např. rozdíl **weather** / **whether**: **cloudy** do vzdálenosti 10 slov / **_ to SLOVESO**
- Učení se kontextových pravidel kombinuje metody s učitelem i bez učitele (supervised i unsupervised)
- Systém využívá váhy získané z trénovacích dat.
- Zdrojem trénovacích data jsou Brown korpus a Wall Street Journal
- Výsledky závisejí na trénovacím korpusu, podstatně **degradují mimo doménu trénovacích textů**.

Příklady využití pravidelnosti české morfologie I.

System ASIMUT

Automatická Selekcce Informací Metodou Úplného Textu (Králíková, Panevová '90)

System měl vyhledávat výskyty zadaných klíčových výrazů v rozsáhlé množině textů (např. sbírka zákonů, různé technické texty, sady návodů apod.), aniž by k tomu používal kompletní slovník českých lemmat.

Klíčovou částí systému byl tzv. **jazykový modul**


Jazykový modul

Neobsahuje žádný rozsáhlý **slovník**. Je založen na **retrográdním slovníku** dr. Slavíčkové (1975) – mnoho slov, která mají v základním tvaru stejný koncový segment, se stejně skloňuje. Výjimky je možné uložit do zvláštního slovníku výjimek, jsou jich řádově pouze stovky (při důkladnějším zpracování max. tisíce).

System ASIMUT

Algoritmus:

1. Porovnávají se jednotlivé znaky zákl.tvaru slova odzadu (háček a čárka jsou zvláštní znaky) dokud není možné (až na výjimky) jednoznačně určit, jak slovo skloňovat (tzn. je určen vzor slova). V průběhu tohoto kroku se také tvoří alternativní kmeny (se změnami kmenových hlásek).



2. Po identifikaci koncového segmentu algoritmus prochází slovník výjimek (pro konkrétní koncový segment).

3. Všem slovním základům (tzn. i základům v případě změn v kmeni) se přidají všechny pádové koncovky pro daný vzor.

System ASIMUT

Příklad koncovek pro vzor Půjčka:

-a, -y, -u, -e M, -ou (K), -ø E K, -ám (K), -ách (K), -ami (K).

Varianty kmenů: Z základní kmen, E vkladné „e” (matka - matek),
K krácení (rána – ranou), M měkčení (louka – louce) apod.

Seznam výjimek:

Instrukce A4 „Ano” (ta vede na vzor F4 (půjčka)):

U následujících slov netvoř E: odmlka, pomlka, zámlka

U následujících slov utvoř K: u Z změň kmenové ou na u: louka

Pro slovo selka tedy algoritmus vygeneruje tvary:

selka, selky, selku, selce, selkou, selek, selkám, selkách, selkami.

System ASIMUT

Problémy

- Není vždy možné jednoznačně určit vzor, ani když se slova liší třeba jen první hláskou (životnost / neživotnost u podst. jmen rodu mužského)
- Příliš hrubá klasifikace (málo vzorů – 31 pro podstatná a přídavná jména), pádové koncovky mají varianty => přegenerování
- Malý rozsah Retrogradního slovníku => je nutné vyhledávat a přidávat výjimky
- Nefunguje tak spolehlivě pro slovesa (příliš velká víceznačnost koncových segmentů základních slovesných tvarů)

Další pojmy

Negativní slovník

Obsahuje slova, která nejsou důležitá při dotazování (spojky, citoslovce apod.) – tato slova jsou odstraněna při předzpracování textu

Konkordance

Při tomto procesu byla všem slovním tvarům nezařazeným do negativního slovníku přiřazena adresa a frekvence výskytu, používaná pro účely urychlení hledání. Slova z negativního slovníku obdržela pouze adresu, která sloužila zejména pro správné určení vzdálenosti mezi jednotlivými významovými slovy v textu. Samotné vyhledávání potom probíhalo na konkordanci.

Příklady využití pravidelnosti české morfologie II.

Automatická indexace českých dokumentů

Standardní přístup k indexaci

Potřebuje slovníky klíčových slov, dokumenty jsou pak indexovány těmito slovy, v úvahu se bere četnost výskytu těchto klíčových slov

Systém Mozaika

MOSAIC - Morphemic Oriented System of Automatic Indexing and Condensation

- využívá toho, že řada přípon a koncovek nese význam, např.:
 - v angličtině *-er* nebo *-or* je **konatel** děje, *-tion* **činnost**, *-ity* nebo *-ness* **vlastnosti**;
 - v češtině *-ič*, *-ač*, *-čka*, *-ér*, *-or*, *-dlo*, *-metr*, *-graf*, *-fon*, *-skop* jsou **nástroje** nebo **přístroje**, *-ace*, *-kce*, *-áž*, *-ní*, *-za* **procesy** nebo **činnosti**,
 - ost*, *-ita*, *-nce* **vlastnosti** a přídavná jména končící na *-aný*, *-ený* jsou **výsledky procesů** zatímco *-ací*, *-ecí* značí **účel**.

Pro pokrytí tématické oblasti elektrických obvodů stačilo 800 přípon, technickou terminologii by pokrylo cca 2000 přípon.

System MOZAIKA

Algoritmus

- Vstupem je nijak nepředzpracovaný text, u kterého je zachováno typografické členění.
- Lematizace a morfologická analýza poskytnou lemata a morfologické značky.
- Nalezená lemata jsou profiltrována a jsou odstraněna např. ta, jejichž kmen nemá vztah k dané tematické oblasti (negativní slovník – malý, řádově desítky slov) či ta, která jsou příliš krátká nebo obsahují nevhodné kombinace hlásek.
- Syntaktická analýza jmenných skupin pomocí jednoduché gramatiky v jazyce Systémů Q pomůže odhalit několikaslovné termíny (*zesilovač* obsah textu charakterizuje mnohem méně než termín *operační zesilovač TESLA KC 415*), u nich se započítávaly i termíny v nich obsažené.
- Přiřazení vah na základě výskytu termínů v různě důležitých místech textu (nadpisy, první a poslední odstavce, první a poslední věty v odstavcích apod. mají vyšší váhu než výskyty uprostřed odstavců).
- Normalizace vah vzhledem k délce dokumentu umožňuje porovnávat relevanci různě dlouhých dokumentů.
- Výstupem je seznam deseti nejvýznamnějších termínů, seřazený podle četnosti jejich výskytu

System MOZAIKA

Výhody

- není nutné vytvářet slovníky odborných termínů, pouze množiny relevantních přípon a koncovek, doplněné o určitou formu negativního slovníku či pravidel
- lokální syntaktická analýza umožňuje větší flexibilitu při hledání termínů

Problémy

- pracné vytváření slovníků a omezujících pravidel v závislosti na tematické oblasti
- neobsahuje řešení odkazů v textech pomocí zájmen, nevyjádřeného podmětu apod., např. „*Jedním z nejvýkonnějších u nás vyráběných přístrojů je operační zesilovač TESLA KC 415. Je vhodným pomocníkem Také je ...*“